




Image

微分方程数值解笔记

目录

第一章 椭圆型方程的差分方法	1
1.1 一个典型例子	1
1.2 求解线性代数方程组的迭代法	6
1.3 二维 Poisson 方程的差分方法	7
1.4 五点差分格式的性质	8
1.4.1 截断误差	8
1.4.2 存在唯一性	9
1.4.3 收敛性	10
1.5 离散后线性方程组基本求解方法	12
1.6 求解五点差分格式的快速 DST 方法	12
1.6.1 求解方法	13
1.6.2 DST 算法	15
1.6.3 各类算法计算时间的比较	15
1.7 两点边值问题的紧致差分格式	16

第一章

椭圆型方程的差分方法

1.1 一个典型例子

例 1.1 如图所示，给定一个各向同性均匀的金属杆，其侧面绝热，有热源作用，求热平衡时的温度分布.




图 1.1: 热传导示意图

我们的目标是对其数学建模.

Step 1. 符号引进

$u(x)$: x 时刻的温度

S : 截面面积

k : 热传导系数

$f(x)$: 热源密度

Step 2. 建立微分方程模型

(1) 热物理的基本假设

Fourier 热传导定律: $dQ = -k\partial_n u dS dt$




图 1.2

(2) 使用微元法建模

在单位时间，考虑微元 $[x, x + \Delta x]$ 的热量变化.

产生的热量为 $\Delta Q = f(x)\Delta x S$, 流出的热量为 $\Delta Q' = -ku'(x + \Delta x)S + ku'(x)S$

由能量守恒定律, $\Delta Q = \Delta Q'$, 即 $f(x)\Delta x S = -(ku')(x + \Delta x)S + (ku')(x)S$

$$\Rightarrow \frac{(ku')(x + \Delta x) - (ku')(x)}{\Delta x} = f(x)$$

令 $\Delta x \rightarrow 0$, $-(ku')'(x) = f(x)$, $0 < x < 1$

除此之外, 对于边界无法使用微元法, 因此需要引入边界条件.

$$\begin{cases} -(ku')'(x) = f(x), 0 < x < 1 \\ u(0) = u(1) = 0 \end{cases} \quad (1.1a)$$

$$\begin{cases} u(0) = u(1) = 0 \end{cases} \quad (1.1b)$$

问题是能否得到 (1.1a)-(1.1b) 的显式解?

为了方便计算, 设 $k(x) = k = 1$, 则上述方程可以简化为

$$\begin{cases} -u''(x) = f(x), 0 < x < 1 \\ u(0) = u(1) = 0 \end{cases} \quad (1.2a)$$

$$\begin{cases} u(0) = u(1) = 0 \end{cases} \quad (1.2b)$$

对第一个式子作积分, 可得 $u'(x) = u'(0) - \int_0^x f(s) ds$.

再作积分可得 $u(x) = u(0) + \int_0^x \left(u'(0) - \int_0^s f(t) dt \right) ds$.

由 $u(0) = 0$, $u(x) = u'(0)x - \int_0^x \int_0^s f(t) dt ds = u'(0)x - \int_0^x (x-s)f(s) ds$.

由 $u(1) = 0$ 知 $u'(0) = \int_0^1 (1-s)f(s) ds$.

令 $\chi_{[0,x]}(s) = \begin{cases} 1, 0 \leq s \leq x \\ 0, x < s \leq 1 \end{cases}$, 那么 $u(x) = \int_0^1 ((1-s)x - \chi_{[0,x]}(s)(x-s)) f(s) ds$.

再记 $K(x, s) = (1-s)x - \chi_{[0,x]}(s)(x-s) = \begin{cases} (1-x)s, 0 \leq s \leq x \\ (1-s)x, x < s \leq 1 \end{cases}$, 则 $u(x) = \int_0^1 K(x, s)f(s) ds$.

由此我们得到了问题的显式解.

□ 注解

上面给出的 $K(x, s)$ 被称为 Green 函数, 它满足 $\begin{cases} -K_x''(x, s) = \delta(x-s), 0 < x < 1 \\ K(0, s) = K(1, s) = 0 \end{cases}$

接下来使用有限差分方程方法求解上述问题.

Step 1. 将 $[0, 1]N$ 等分, 得格点 $x_0 = 0 < x_1 < \cdots < x_N = 1$, 其中 $x_i = ih, h = \frac{1}{N}$.

Step 2. 计算 $\{u(x_i)\}_{i=0}^N$, 下面需要建立差分方程模型.

- 当 $x = 0, 1$ 时,

$$u(0) = 0 \quad (1.3a)$$

$$u(1) = 0 \quad (1.3b)$$

- 当 $x = x_i, 1 \leq i \leq N-1$, $-u''(x_i) = f_i = f(x_i)$.

但二阶导数依旧无法直接计算, 因此需要使用差商近似求导.

以 x_i 为中心, 使用二阶中心差商近似二阶导数, 即 $u''(x_i) \approx \frac{u_{i+1} - 2u_i + u_{i-1}}{h^2}$.

因此

$$-\frac{u_{i+1} - 2u_i + u_{i-1}}{h^2} = f_i \quad (1.3c)$$

上述的 (1.3a)-(1.3c) 就是完整的有限差分法, 因此可以得到近似解 $u_i \approx u(x_i), 0 \leq i \leq N$

最终我们得到的差分方程模型为

$$\begin{cases} -\frac{u_{i+1} - 2u_i + u_{i-1}}{h^2} = f_i, 1 \leq i \leq N-1 \\ u_0 = u_N = 0 \end{cases} \quad (1.4a)$$

$$(1.4b)$$

a. 离散后问题之解是否唯一 下面开始研究 (4a)-(4b).

当 $i = 1$ 时, $-\frac{u_2 - 2u_1 + u_0}{h^2} = f_1$. 当 $i = N$ 时, $-\frac{u_N - 2u_{N-1} + u_{N-2}}{h^2} = f_{N-1}$.

因此可知 $\begin{cases} -\frac{u_2 - 2u_1 + u_0}{h^2} = f_1 \\ -\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2} = f_i, 2 \leq i \leq N-2 \\ -\frac{u_N - 2u_{N-1} + u_{N-2}}{h^2} = f_{N-1} \end{cases}$. 上述方程可以写成矩阵形式

$$A_{N-1} \vec{u} = \vec{f} \quad (1.5)$$

$$\text{, 其中 } A_{N-1} = -\frac{1}{h^2} \begin{bmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ 0 & -1 & 2 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 2 \end{bmatrix}, \vec{u} = [u_1, u_2, \dots, u_{N-1}]^T, \vec{f} = [f_1, f_2, \dots, f_{N-1}]^T$$

(1.5) 存在唯一解当且仅当 A_{N-1} 可逆, 针对这一点, 有以下方法可以证明

1. 不可约对角占有矩阵可逆
2. 利用递推求其行列式, 行列式不为零
3. A_{N-1} 为对称阵, 因此行列式等于特征值之和

b. 局部可靠性 除了可解性外, 另外一个指标是方法的截断误差.

设 $u(x)$ 是微分方程的充分光滑解, 取 $u_i = u(x_i)$, 考查 $R_i = -\frac{u(x_{i+1}) - 2u(x_i) + u(x_{i-1}))}{h^2} - f(x_i)$ 的大小, 由 Talor 展开知

命题 1.1 (二阶导数的二阶中心差商逼近公式)

$$u''(x_i) = \frac{u(x_{i+1}) - 2u(x_i) + u(x_{i-1}))}{h^2} - \frac{1}{12}h^2u^{(4)}(\xi_i), x_{i-1} \leq \xi_i \leq x_{i+1}$$

因此

$$R_i = -\frac{1}{12}h^2u^{(4)}(\xi_i) \quad (1.6)$$

这表明当 $h \rightarrow 0$ 时, $R_i \rightarrow 0$, 故该方法是相容的, 且截断误差关于 h 是二阶的.

c. **稳定性** 下面的问题是这个结果是否稳定.

上述问题的理论预期结果为

$$\begin{cases} -\frac{u_{i+1} - 2u_i + u_{i-1}}{h^2} = f_i, \\ u_0 = u_N = 0 \end{cases} \quad (1.7)$$

实际的计算结果为

$$\begin{cases} -\frac{u_{i+1}^* - 2u_i^* + u_{i-1}^*}{h^2} = f_i^* = f_i + \varepsilon_i, \\ u_0^* = u_N^* = 0 \end{cases} \quad (1.8)$$

其中 ε_i 为舍入误差或是测量误差.

现在引入误差 $E_i = u_i^* - u_i$, 这个误差就可能是由计算工具等外部因素引发的, 我们希望这个误差也应当是可控的, 不然就会出现虽然算法本身可靠, 但由于客观无法避免的误差导致结果相距甚远. 将 (1.7) 与 (1.8) 相减可得

$$\begin{cases} -\frac{E_{i+1} - 2E_i + E_{i-1}}{h^2} = \varepsilon_i, \\ E_0 = E_N = 0 \end{cases} \quad (1.9)$$

现在的问题是如果在已知右端 ε_i 的大小的前提下, 我们如何可以计算出 E_i 的大小. 解决上述问题需要使用到离散极值原理.

引理 1.1 (离散极值原理)

任给一组实数 $y_i, i = 0, 1, 2, \dots, N$, 记

$$l(y_i) = \frac{y_{i+1} - 2y_i + y_{i-1}}{h^2}.$$

若 $l(y_i) \geq 0, i = 1, 2, \dots, N-1$, 则 y_0 或 y_N 必为 $\{y_i\}_{i=0}^N$ 的最大值.

若 $l(y_i) \leq 0, i = 1, 2, \dots, N-1$, 则 y_0 或 y_N 必为 $\{y_i\}_{i=0}^N$ 的最小值.

如果从连续的情形来看, $l(y_i)$ 实际上就是这一点的二阶导数, 因此 $y''(x) \geq 0$ 或 $y''(x) \leq 0$, 这表明 $y(x)$ 是一个凸函数或凹函数, 从而最大最小值在两端取到. 而对于离散的本情形, 可以使用反证法予以证明.

证明 以 $l(y_i) \geq 0$ 为例, 假设 $y_k, 1 \leq k \leq N-1$ 为最大值.

则 $y_k \geq y_{k-1}$ 且 $y_k \geq y_{k+1}$, 从而 $l(y_k) = \frac{y_{k+1} - 2y_k + y_{k-1}}{h^2} \geq 0$, 矛盾! □

现在我们可以构造两个辅助序列

$$\begin{cases} -\frac{E_{i+1}^* - 2E_i^* + E_{i-1}^*}{h^2} = \varepsilon, \\ E_0^* = E_N^* = 0. \end{cases} \quad (1.10)$$

$$\begin{cases} -\frac{\tilde{E}_{i+1} - 2\tilde{E}_i + \tilde{E}_{i-1}}{h^2} = -\varepsilon, \\ \tilde{E}_0 = \tilde{E}_N = 0. \end{cases} \quad (1.11)$$

这里, $\varepsilon = \max_{1 \leq i \leq N-1} |\varepsilon_i|$. 设 $y_i = E_i - E_i^*$, 则由 (1.9) 和 (1.10) 立得

$$l(y_i) = l(E_i) - l(E_i^*) = \varepsilon - \varepsilon_i \geq 0, \quad 1 \leq i \leq N-1, \quad y_0 = y_N = 0.$$

故由离散极值原理有 $y_i \leq 0$, 即 $E_i \leq E_i^*, i = 0, 1, \dots, N$. 同理由 (1.9) 和 (1.11) 可知

$$\tilde{E}_i \leq E_i, \quad i = 0, 1, \dots, N.$$

E^* 的连续化情形是一个二阶常微分方程
$$\begin{cases} -\rho''(x) = \varepsilon, 0 < x < 1 \\ \rho(0) = \rho(1) = 0 \end{cases}, \quad \text{因此 } \rho(x) = \frac{\varepsilon}{2}x(1-x),$$

是一个二次多项式.

由 (1.6) 可知, 当精确解为小于三阶的多项式时差分方法 (1.4) 可获得精确解, 于是

$$E_i^* = \rho(x_i) = \frac{\varepsilon}{2}x_i(1-x_i).$$

从而有

$$|E_i| \leq \frac{\varepsilon}{2} \max_{0 \leq x \leq 1} |x(1-x)| = \frac{\varepsilon}{8},$$

换言之,

$$\max_{1 \leq i \leq N-1} |u_i^* - u_i| \leq \frac{1}{8} \max_{1 \leq i \leq N-1} |\varepsilon_i|. \quad (1.12)$$

这说明方法是稳定的, 不会出现“差之毫厘, 谬以千里”的现象.

d. 收敛性 问题: 我们现在知道截断误差的大小. 下一步要进一步分析 u_i 作为 $u(x_i)$ 的近似值, 两者究竟相差多少?

由前面的截断误差分析知

$$-\frac{u(x_{i+1}) - 2u(x_i) + u(x_{i-1}))}{h^2} = f_i + R_i = f_i - \frac{1}{12}h^2 u^{(4)}(\xi_i).$$

将 $u(x_i)$ 和 u_i^* 比较, 可以发现那里的 ε_i 就是这里的 R_i . 因此, 根据稳定性估计 (1.12) 可得

$$\max_{1 \leq i \leq N-1} |u(x_i) - u_i| \leq \frac{1}{8} \max_{1 \leq i \leq N-1} |R_i| \leq \frac{1}{96}h^2 M_4,$$

式中 $M_4 = \max_{0 \leq x \leq 1} |u^{(4)}(x)|$. 故得所需结果.

e. 离散后问题的求解 可用追赶法或迭代法来求解.

回顾以上推导过程, 可知建立微分方程有限差分方法并进行理论分析的基本要素是:

- 网格点的确定;
- 方程和边界条件在网格点的离散;
- 理论分析的关键为离散极值原理.

□ 注解

著名数学家冯康 (1920 - 1993) 曾将物理模型问题数值解归结为以下几步:

物理定律 $\xrightarrow{\text{解析化}}$ 数学模型 $\xrightarrow{\text{代数化}}$ 离散化 $\xrightarrow{\text{算术化}}$ 上机计算.

这是对偏微分方程数值解核心思想的精辟阐述.

1.2 求解线性代数方程组的迭代法

给定线性代数方程组: $\mathbf{Ax} = \mathbf{b}$, 式中 $\mathbf{A}$ 为非奇异矩阵.

将 $\mathbf{A}$ 作矩阵分裂可得 $\mathbf{A} = \mathbf{M} - \mathbf{N}$, 式中 $\mathbf{M}$ 是非奇异矩阵.

那么上述线性代数方程组可以转化为 $\mathbf{Mx} = \mathbf{Nx} + \mathbf{b}$.

从而得到如下迭代法: $\mathbf{Mx}_{k+1} = \mathbf{Nx}_k + \mathbf{b}$, 即

$$\mathbf{x}_{k+1} = \mathbf{M}^{-1}\mathbf{Nx}_k + \mathbf{M}^{-1}\mathbf{b} = \mathbf{Sx}_k + \mathbf{M}^{-1}\mathbf{b}. \quad (1.13)$$

其中 x_0 是我们的初始猜测.

由于该方法将一个方程组求解的过程拆分为若干个不同的线性方程组的求解, 因此我们希望每一个线性方程组的求解都比较简单, 因此在实际应用中应该取 $\mathbf{M}$ 使得能够高效求解线性方程组 $\mathbf{My} = \mathbf{c}$.

除此之外, 还必须保证迭代法的收敛性, 即 $\mathbf{S} = \mathbf{M}^{-1}\mathbf{N}$ 的谱半径 $\rho(\mathbf{S}) < 1$.

基于 (1.14) 还可得阻尼迭代法 (Damped Iterative Method):

$$\begin{cases} \tilde{\mathbf{x}}_{k+1} = \mathbf{M}^{-1}\mathbf{Nx}_k + \mathbf{M}^{-1}\mathbf{b}, \\ \mathbf{x}_{k+1} = \omega\tilde{\mathbf{x}}_{k+1} + (1 - \omega)\mathbf{x}_k = [\omega\mathbf{M}^{-1}\mathbf{N} + (1 - \omega)\mathbf{I}]\mathbf{x}_k + \omega\mathbf{M}^{-1}\mathbf{b}, \end{cases} \quad (1.14)$$

式中 ω 是阻尼参数, 而 $\mathbf{I}$ 表示单位矩阵. 阻尼迭代法就是将计算后的结果和原先的结果作组合得到下一步迭代的初始值.

(1.14) 和 (1.15) 都可视为基于矩阵分裂的迭代法.

关于 $\mathbf{M}$ 的常用选取导出的迭代方法包括:

1. 在 (1.14) 中取

$$\mathbf{M} = \mathbf{D} = \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

即得 Jacobi 迭代法.

2. 在 (1.14) 中取

$$\mathbf{M} = \mathbf{L} = \begin{bmatrix} a_{11} & & & & \\ a_{21} & a_{22} & & & \\ a_{31} & a_{32} & a_{33} & & \\ \vdots & \vdots & \ddots & \ddots & \\ a_{n1} & a_{n2} & \cdots & a_{n,n-1} & a_{nn} \end{bmatrix}$$

即得 Gauss-Seidel 迭代法.

3. 在 (1.15) 中同上选取 $\mathbf{M}$ 即得 SOR 迭代法.

1.3 二维 Poisson 方程的差分方法

考虑如下带 Dirichlet 边界条件的 Poisson 方程:

$$\begin{cases} \Delta u(x, y) = f(x, y), & (x, y) \in \Omega, \\ u(x, y) = \alpha(x, y), & (x, y) \in \partial\Omega, \end{cases} \quad (1.15)$$

式中 $\Omega = (0, a) \times (0, b)$, f 是定义在 Ω 上某一函数, 而 α 是定义在 Ω 边界 $\partial\Omega$ 上的某一函数.

先来导出求解以上 Poisson 方程的五点差分格式. 将区域 Ω 在 x 方向和 y 方向分别进行 $I+1$ 和 $J+1$ 等分, 则 x 方向和 y 方向的网格步长分别为

$$h = a/(I+1), \quad k = b/(J+1),$$

所得网格点为 (x_i, y_j) , 式中 $x_i = ih, y_j = jk, 0 \leq i \leq I+1, 0 \leq j \leq J+1$.




图 1.3: 二维网格示意图

将相应的内点集和边界点集分别记为

$$\Omega_h = \{(x_i, y_j) : 1 \leq i \leq I, 1 \leq j \leq J\},$$

$$\partial\Omega_h = \{(x_i, y_j) : i = 0 \text{ 或 } I+1, j = 0 \text{ 或 } J+1\}.$$

将其分类的原因是对于内格点, 其满足微分方程, 而对于外格点, 直接使用边界条件即可. 现在将网格点上的连续信息离散化.

- 当 $(x_i, y_j) \in \partial\Omega_h$ 时, 有 $u_{ij} = \alpha(x_i, y_j) = \alpha_{ij}$;
- 当 $(x_i, y_j) \in \Omega_h$ 时, 如下图所示, 对二阶偏导均用二阶中心差商离散,

可得

$$\Delta_h u_{ij} := \frac{u_{i+1,j} - 2u_{ij} + u_{i-1,j}}{h^2} + \frac{u_{i,j+1} - 2u_{ij} + u_{i,j-1}}{k^2} = f(x_i, y_j) = f_{ij}.$$

故得求解 Poisson 方程 (1.15) 的五点差分格式如下:

$$\begin{cases} \Delta_h u_{ij} = f_{ij}, & (x_i, y_j) \in \Omega_h, \\ u_{ij} = \alpha_{ij}, & (x_i, y_j) \in \partial\Omega_h. \end{cases} \quad (1.16)$$




图 1.4: 五点差分格式节点示意图

1.4 五点差分格式的性质

1.4.1 截断误差

设 u 为问题 (1.15) 的充分光滑解, $u_{ij} = u(x_i, y_j)$.

当 $(x_i, y_j) \in \partial\Omega$ 时, $u_{ij} - \alpha_{ij} = 0$.

当 $(x_i, y_j) \in \Omega$ 时, 由截断误差的定义知

$$\begin{aligned} R_h u_{ij} &= \frac{u(x_i + h, y_j) - 2u(x_i, y_j) + u(x_i - h, y_j)}{h^2} \\ &\quad + \frac{u(x_i, y_j + k) - 2u(x_i, y_j) + u(x_i, y_j - k)}{k^2} - f(x_i, y_j) \\ &=: I_1 + I_2 - \Delta u(x_i, y_j). \end{aligned}$$

根据 Taylor 展开有

$$\begin{aligned} u(x_i \pm h, y_j) &= u(x_i, y_j) \pm hu_x(x_i, y_j) + \frac{1}{2}h^2u_{xx}(x_i, y_j) \\ &\quad \pm \frac{1}{3!}h^3u_{xxx}(x_i, y_j) + \frac{1}{4!}h^4u_{xxxx}(x_i + \xi_{\pm}h, y_j), \quad |\xi_{\pm}| < 1. \end{aligned}$$

于是

$$\begin{aligned} I_1 &= u_{xx}(x_i, y_j) + \frac{1}{12}h^2 \times \frac{1}{2} \{u_{xxxx}(x_i + \xi_+h, y_j) + u_{xxxx}(x_i + \xi_-h, y_j)\} \\ &= u_{xx}(x_i, y_j) + \frac{1}{12}h^2u_{xxxx}(x_i + \xi h, y_j), \quad |\xi| < 1. \end{aligned}$$

类似可知,

$$\begin{aligned} u(x_i, y_j \pm k) &= u(x_i, y_j) \pm ku_y(x_i, y_j) + \frac{1}{2}k^2u_{yy}(x_i, y_j) \\ &\quad \pm \frac{1}{3!}k^3u_{yyy}(x_i, y_j) + \frac{1}{4!}k^4u_{yyyy}(x_i, y_j + \eta_{\pm}k), \quad |\eta_{\pm}| < 1. \\ I_2 &= u_{yy}(x_i, y_j) + \frac{1}{12}k^2u_{yyyy}(x_i, y_j + \eta k), \quad |\eta| < 1. \end{aligned}$$

所以, 差分格式 (1.16) 的截断误差为

$$R_h u_{ij} = \frac{1}{12} \{h^2u_{xxxx}(x_i, y_j + \xi h) + k^2u_{yyyy}(x_i, y_j + \eta k)\}, \quad |\xi|, |\eta| < 1. \quad (1.17)$$

1.4.2 存在唯一性

问题: 如何得到差分格式 (1.16) 的矩阵描述? 若要深入研究, 我们需要 Kronecker 张量积以及矩阵的拉直运算. 但同时, 我们也存在一些较为基础的方法.

若 (1.16) 可以写成 $A\vec{x} = \vec{u}$ 的形式, 其解存在唯一 $\iff$ 若 $\vec{f} = \vec{0}$, 则 $\vec{u} = \vec{0}$.

将其离散化, 若 $f_{ij} = 0, \alpha_{ij} = 0$, 能否得到 $u_{ij} = 0$, 这一结构提示我们需要使用 2 维形式的离散极值原理.

引理 1.2 (离散极值原理)

设 u_{ij} 是定义在 $\Omega_h \cup \partial\Omega_h$ 上的格点函数,

(1) 如果当 $(x_i, y_j) \in \Omega_h$ 时 $\Delta_h u_{ij} \geq 0$, 则成立

$$\max_{\Omega_h} u_{ij} \leq \max_{\partial\Omega_h} u_{ij}. \quad (1.18)$$

(2) 如果当 $(x_i, y_j) \in \Omega_h$ 时 $\Delta_h u_{ij} \leq 0$, 则成立

$$\min_{\partial\Omega_h} u_{ij} \leq \min_{\Omega_h} u_{ij}. \quad (1.19)$$

证明 用反证法证明 (1.19). 假设 (1.19) 不成立, 则存在 $(x_{i_0}, y_{j_0}) \in \Omega_h$ 使得

$$M = \max_{\Omega_h} u_{ij} = u_{i_0 j_0} > \max_{\partial\Omega_h} u_{ij}. \quad (1.20)$$

在 (x_{i_0}, y_{j_0}) 处考察差分方程 (1.16) 有

$$\Delta_h u_{i_0 j_0} = \frac{1}{h^2} \{u_{i_0+1, j_0} - 2u_{i_0 j_0} + u_{i_0-1, j_0}\} + \frac{1}{k^2} \{u_{i_0, j_0+1} - 2u_{i_0 j_0} + u_{i_0, j_0-1}\} \geq 0,$$

即

$$2 \left(\frac{1}{h^2} + \frac{1}{k^2} \right) M \leq \frac{1}{h^2} \{u_{i_0+1, j_0} + u_{i_0-1, j_0}\} + \frac{1}{k^2} \{u_{i_0, j_0+1} + u_{i_0, j_0-1}\}.$$

若格点函数 u_{ij} 在 (x_{i_0}, y_{j_0}) 的某一相邻格点的函数值小于 M , 则与上一不等式矛盾. 故有

$$u_{i_0, j_0+1} = u_{i_0, j_0-1} = u_{i_0+1, j_0} = u_{i_0-1, j_0} = M.$$

对以上四邻点 (如仍为 Ω_h 中的格点) 进行同样推理, 反复进行该过程, 最后必能找到某边界格点 $(x_{i_1}, y_{j_1}) \in \partial\Omega_h$ 使得 $u_{i_1 j_1} = M$, 这与假设 (1.21) 相矛盾. $\square$

引理 1.3 (连续情形极值原理)

若在单连通区域 Ω 中成立 $\Delta u \geq 0$, 可知

$$\max_{\Omega} u = \max_{\partial\Omega} u. \quad (1.21)$$

定理 1.1

差分格式 (1.16) 之解存在唯一.

证明 只须证明若格点函数 u_{ij} 满足 $f_{ij} = 0, \alpha_{ij} = 0 \Rightarrow u_{ij} = 0$ 即可.

当 $(x_i, y_j) \in \Omega_h$ 时, $\Delta_h u_{ij} = 0$, 即 $\Delta_h u_{ij} \geq 0, (x_i, y_j) \in \Omega_h$.

故 $\max_{\Omega_h} u_{ij} = \max_{\partial\Omega_h} u_{ij} = \max_{\partial\Omega_h} \alpha_{ij} = 0$.

类似可知, $\min_{\Omega_h} u_{ij} = 0$.

因此 $u_{ij} \equiv 0$, 得证. □

1.4.3 收敛性

定理 1.2 (离散最大模估计)

设 u_{ij} 为定义在 $\Omega_h \cup \partial\Omega_h$ 上的格点函数, 则

$$\max_{\Omega_h} |u_{ij}| \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 \max_{\Omega_h} |\Delta_h u_{ij}|.$$

证明 设 $A = \max_{\Omega_h} |\Delta_h u_{ij}|$. 构造辅助格点函数 $w_{ij}^\pm = \pm u_{ij} + \frac{1}{2}x_i^2 A$.

则有

$$\Delta_h w_{i,j}^\pm = \pm \Delta_h u_{ij} + \Delta \left(\frac{1}{2}x_i^2 + A \right) = \pm \Delta_h u_{ij} + A \geq 0.$$

根据**离散极值原理**, 对于满足 $\Delta_h w \geq 0$ 的格点函数, 其最大值必在边界 $\partial\Omega_h$ 上达到, 即:

$$\max_{\Omega_h} w_{ij}^\pm \leq \max_{\partial\Omega_h} w_{ij}^\pm.$$

在区域内 $0 \leq x_i \leq a$, 有 $\max_{\partial\Omega_h} w_{ij}^\pm = \max_{\partial\Omega_h} \left\{ \pm u_{ij} + \frac{A}{2}x_i^2 \right\} \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 A$.

结合上述两步, 对于 Ω_h 中的任意点, 均有:

$$\pm u_{ij} \leq \pm u_{ij} + \frac{A}{2}x_i^2 = w_{ij}^\pm \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 A.$$

上式对 $+u_{ij}$ 和 $-u_{ij}$ 同时成立, 故有:

$$|u_{ij}| \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 A, \quad \forall (i, j) \in \Omega_h.$$

最后对左端取最大值, 并将 A 的定义代回, 即得:

$$\max_{\Omega_h} |u_{ij}| \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 \max_{\Omega_h} |\Delta_h u_{ij}|.$$

□

对应的连续情形的极值估计为

定理 1.3 (连续最大模估计)

$$\max_{\Omega} |u(x, y)| \leq \max_{\partial\Omega} |u(x, y)| + \frac{1}{2}a^2 \max_{\Omega} |\Delta u(x, y)|.$$

除此之外, 可以通过待定系数方法来给出辅助格点函数的构造, 而不只局限于特定形式.

定义格点函数 $w_{ij}^\pm = \pm u_{ij} + \phi_{ij} A$, 其中 $\phi = \phi(x, y)$ 是待定函数.

我们希望选取合适的 ϕ 使得 $w_{ij}^\pm$ 满足离散最大值原理, 即 $\Delta_h w_{ij}^\pm \geq 0$. 直接计算有

$$\Delta_h w_{ij}^\pm = \pm \Delta_h u_{ij} + (\Delta_h \phi_{ij}) A.$$

注意到 $\pm \Delta_h u_{ij} + A \geq 0$, 因此如果要求

$$\Delta_h \phi_{ij} \geq 1, \tag{1.22}$$

则

$$\Delta_h w_{ij}^{\pm} = \pm \Delta_h u_{ij} + (\Delta_h \phi_{ij})A \geq 0.$$

在此情形下, 有

$$\max_{\Omega_h} w_{ij}^{\pm} \leq \max_{\partial\Omega_h} w_{ij}^{\pm} = \max_{\partial\Omega_h} \{\pm u_{ij} + \phi_{ij}A\} \leq \max_{\partial\Omega_h} |u_{ij}| + (\max_{\partial\Omega_h} \phi_{ij})A,$$

$$\begin{aligned} \text{从而 } \max_{\Omega_h} |u_{ij}| &= \max_{\Omega_h} (\pm u_{ij}) = \max_{\Omega_h} (w_{ij}^{\pm} - \phi_{ij}A) \\ &\leq \max_{\Omega_h} w_{ij}^{\pm} + (\max_{\Omega_h} (-\phi_{ij}))A \\ &\leq \max_{\partial\Omega_h} |u_{ij}| + \alpha_h A = \max_{\partial\Omega_h} |u_{ij}| + \alpha_h \max_{\Omega_h} |\Delta_h u_{ij}|, \end{aligned}$$

$$\text{式中 } \alpha_h = \max_{\partial\Omega_h} \phi_{ij} + \max_{\Omega_h} (-\phi_{ij})$$

在离散最大模估计的证明过程中, 我们就是将待定函数定义为 $\phi(x, y) = \frac{1}{2}x^2, (x, y) \in \bar{\Omega}$.

事实上, 二阶中心差商对三次多项式是精确的, 所以 $\Delta_h \phi_{ij} = 1$, 满足条件 (1.22), 且有

$$\max_{\Omega_h} |u_{ij}| \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{2}a^2 \max_{\Omega_h} |\Delta_h u_{ij}|.$$

初次之外, 若选取 $\phi(x, y) = \frac{1}{4}(x^2 + y^2 - x - y), (x, y) \in \bar{\Omega} = [0, a] \times [0, b]$, 且设 $a = b = 1$, 则有 $\Delta_h \phi_{ij} = 1$, 且成立

$$\max_{\Omega_h} |u_{ij}| \leq \max_{\partial\Omega_h} |u_{ij}| + \frac{1}{8} \max_{\Omega_h} |\Delta_h u_{ij}|.$$

$$\text{由截断误差定义可知 } \begin{cases} \Delta_h u(x_i, y_j) = f_{ij} + R_{ij} \\ u_{x_i, y_j} = \alpha_{ij} \end{cases}$$

$$\Rightarrow \begin{cases} \Delta_h (u(x_i, y_j) - u_{ij}) = R_{ij} \\ u_{x_i, y_j} - u_{i,j} = 0 \end{cases}$$

由离散最大模估计可知

$$\max_{\Omega_h} |u(x_i, y_j) - u_{ij}| \leq \frac{1}{2}a^2 \max_{\Omega_h} |R_{ij}|.$$

更进一步可以得到以下定理

定理 1.4 (五点差分格式的收敛性与误差)

如果 u 为 Poisson 方程 Dirichlet 边值问题

$$\begin{cases} \Delta u = f, & (x, y) \in \Omega, \\ u = \alpha, & (x, y) \in \partial\Omega \end{cases}$$

之解, 满足 $u \in C^4(\bar{\Omega})$, 则五点差分格式 (1.16) 收敛并有误差估计

$$\max_{\Omega_h} |u_{ij} - u(x_i, y_j)| \leq \frac{1}{24}a^2 \|u\|_{C^4(\bar{\Omega})} (h^2 + k^2).$$

1.5 离散后线性方程组基本求解方法

现在来介绍差分格式 (1.16) 导出的线性方程组基本求解方法. 为讨论方便, 不妨设 $h = k$. 先改写原差分方程为如下不动点形式:

$$\begin{cases} u_{ij} = \frac{1}{4}\{u_{i+1,j} + u_{i-1,j} + u_{i,j+1} + u_{i,j-1}\} - \frac{1}{4}h^2 f_{ij}, \\ u_{ij} = \alpha_{i,j}. \end{cases}$$

由此可得求解 (1.16) 的下述迭代方法:

1. Jacobi 迭代法

$$\begin{cases} u_{ij}^{new} = \frac{1}{4}\{u_{i+1,j}^{old} + u_{i-1,j}^{old} + u_{i,j+1}^{old} + u_{i,j-1}^{old}\} - \frac{1}{4}h^2 f_{ij}, \\ u_{ij}^{new} = u_{ij}^{old} = \alpha_{i,j}. \end{cases}$$

2. Gauss-Seidel 迭代法 计算顺序: 从左到右, 从下到上.

$$\begin{cases} u_{ij}^{new} = \frac{1}{4}\{u_{i-1,j}^{new} + u_{i,j-1}^{new} + u_{i+1,j}^{old} + u_{i,j+1}^{old}\} - \frac{1}{4}h^2 f_{ij}, \\ u_{ij}^{new} = u_{ij}^{old} = \alpha_{i,j}. \end{cases}$$

Gause-Seidel 迭代法在每次迭代时都会在下侧和左侧使用最新的迭代结果, 而上方和右方使用原先的迭代结果.

3. SOR 迭代法

$$u_{ij}^{new} = \omega \tilde{u}_{ij}^{new} + (1 - \omega)u_{ij}^{old},$$

式中, $\tilde{u}_{ij}^{new}$ 由 Gauss-Seidel 迭代法给出, 而 ω 为松弛参数.

1.6 求解五点差分格式的快速 DST 方法

不失一般性, 设 Poisson 方程 (1.15) 满足齐次 Dirichlet 边界条件, 即 $\alpha \equiv 0$; 且设 $a = b = 1$. 则求解它的五点差分格式可写成如下矩阵方程:

$$AU + UB = F \quad (1.23)$$

注意, 虽然方程应当是 $\Delta u = f$, 但在此处我们将其写为 $-\Delta u = -f$, 这样做的好处是此时 $-\Delta$ 是一个对称正定算子.

相关矩阵定义如下:

$$A = \frac{1}{h^2} \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix}_{I \times I}, \quad B = \frac{1}{k^2} \begin{bmatrix} 2 & -1 & & & \\ -1 & 2 & -1 & & \\ & \ddots & \ddots & \ddots & \\ & & -1 & 2 & -1 \\ & & & -1 & 2 \end{bmatrix}_{J \times J}.$$

其中未知量矩阵 U 与右端项矩阵 F 为:

$$U = \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1J} \\ u_{21} & u_{22} & \cdots & u_{2J} \\ \cdots & \cdots & \cdots & \cdots \\ u_{I1} & u_{I2} & \cdots & u_{IJ} \end{bmatrix}, \quad F = - \begin{bmatrix} f_{11} & f_{12} & \cdots & f_{1J} \\ f_{21} & f_{22} & \cdots & f_{2J} \\ \cdots & \cdots & \cdots & \cdots \\ f_{I1} & f_{I2} & \cdots & f_{IJ} \end{bmatrix}.$$

△ 问题

如记 $T(U) = AU + UB$, 它为 $\mathbb{R}^{I \times J}$ 到 $\mathbb{R}^{I \times J}$ 的线性变换, 请问它的特征值是多少?

1.6.1 求解方法

方法一

将未知矩阵拉直获得列向量, 形成线性方程组

$$(I \otimes A + B \otimes I) \vec{X} = \vec{F},$$

式中, $\vec{\cdot}$ 是矩阵的按列拉直运算而 $\otimes$ 表示矩阵的 **Kronecker 积** 运算.

定义 1.1 (Kronecker 张量积)

设 $A \in \mathbb{R}^{m \times n}, B \in \mathbb{R}^{p \times q}$, 则

$$A \otimes B = \begin{bmatrix} a_{11}B & \cdots & a_{1n}B \\ \vdots & \ddots & \vdots \\ a_{m1}B & \cdots & a_{mn}B \end{bmatrix}.$$

矩阵的张量积和拉直运算之间满足如下性质.

性质 1.1

$$\overrightarrow{AXB} = (B^T \otimes A) \vec{X}.$$

那么最终得到的线性方程组中的矩阵是一个分块三对角矩阵, 从而可以使用各类方法求解.

方法二: 直接操作

$A = \frac{1}{h^2} = \frac{1}{h^2}(2I - H_I), B = \frac{1}{k^2} = \frac{1}{k^2}(2I - H_J)$, 其中 H_N 为三对角矩阵:

$$H_N = \begin{bmatrix} 0 & 1 & & & \\ 1 & 0 & 1 & & \\ & \ddots & \ddots & \ddots & \\ & & \ddots & \ddots & 1 \\ & & & 1 & 0 \end{bmatrix}_{N \times N}.$$

对于 H_N , 其特征根为: $\lambda = \lambda_k = 2 \cos \theta_k, \quad 1 \leq k \leq N$.

相应的特征向量为: $\vec{y}^{(k)} = [\sin(\theta_k), \sin(2\theta_k), \cdots, \sin(N\theta_k)]^T$, 其中 $\theta_k = \frac{k\pi}{N+1}, 1 \leq k \leq N$.

由线性代数的知识, 若 $A = f(B)$, 其中 f 是多项式函数, 且 λ 为 B 的特征值, 那么 $f(\lambda)$ 是 A 的特征值.

因此就可以计算矩阵 A 与 B 的特征值:

- 矩阵 A 的特征值为: $\lambda_i = \frac{4}{h^2} \sin^2 \frac{i\pi}{2(I+1)}, \quad 1 \leq i \leq I.$

对应的特征向量为 $\vec{p}_i = \left[\sin \frac{i\pi}{I+1}, \sin \frac{2i\pi}{I+1}, \dots, \sin \frac{Ii\pi}{I+1} \right]^T.$

- 矩阵 B 的特征值为: $\mu_j = \frac{4}{k^2} \sin^2 \frac{j\pi}{2(J+1)}, \quad 1 \leq j \leq J.$

对应的特征向量为 $\vec{q}_j = \left[\sin \frac{j\pi}{J+1}, \sin \frac{2j\pi}{J+1}, \dots, \sin \frac{Jj\pi}{J+1} \right]^T.$

! 重要

重要关系:

$$\vec{p}_i^T \vec{p}_j = \frac{I+1}{2} \delta_{ij}, \quad \vec{q}_i^T \vec{q}_j = \frac{J+1}{2} \delta_{ij},$$

式中 δ_{ij} 为 Kronecker 记号.

- 将矩阵 A 的特征向量 $\mathbf{p}_i, 1 \leq i \leq I$ 按列排列形成矩阵 $[\mathbf{p}_1 \mathbf{p}_2 \cdots \mathbf{p}_I]$ 记为 P . 那么 P 的第 (i, j) 元素为 $\sin \frac{ij\pi}{I+1}$, 故它是对称矩阵.
- 将矩阵 B 的特征向量 $\mathbf{q}_j, 1 \leq j \leq J$ 按列排列形成矩阵 $[\mathbf{q}_1 \mathbf{q}_2 \cdots \mathbf{q}_J]$ 记为 Q . Q 的第 (i, j) 元素为 $\sin \frac{ij\pi}{J+1}$, 故它也是对称矩阵.

记 $P_1 = \sqrt{2h}P, P_2 = \sqrt{2k}Q$, 由于 $\frac{I+1}{2} = \frac{1}{2h}, \frac{J+1}{2} = \frac{1}{2k}$, 易知它们均为正交阵, 且成立

$$A = P_1 \Lambda_1 P_1^T, \quad B = P_2 \Lambda_2 P_2^T,$$

式中,

$$\Lambda_1 = \text{diag}(\lambda_1, \dots, \lambda_I), \quad \Lambda_2 = \text{diag}(\mu_1, \dots, \mu_J).$$

于是矩阵方程可重写为

$$P_1 \Lambda_1 P_1^T U + U P_2 \Lambda_2 P_2^T = F.$$

在方程两边同时左乘 P_1^T , 右乘 P_2 , 得到 $\Lambda_1 (P_1^T U P_2) + (P_1^T U P_2) \Lambda_2 = P_1^T F P_2$.

记 $P_1^T U P_2 = U_1, P_1 F P_2 = F_1$, 则方程又化为 $\Lambda_1 U_1 + U_1 \Lambda_2 = F_1$.

$U_1 \in \mathbb{R}^{I \times J}$, 考查上式中 (i, j) 元素, 则有 $(\lambda_i + \mu_j)(U_1)_{ij} = (F_1)_{ij}$, 即

$$(U_1)_{ij} = \frac{(F_1)_{ij}}{\lambda_i + \mu_j}, \quad 1 \leq i \leq I, 1 \leq j \leq J. \quad (1.24)$$

更详细地写开,

$$U = \sum_{i=1}^I \sum_{j=1}^J \frac{4\mathbf{p}_i^T F \mathbf{q}_j}{(\lambda_i + \mu_j)(I+1)(J+1)} \mathbf{p}_i \mathbf{q}_j^T. \quad (1.25)$$

△ 问题

如何将以上表达式矩阵化表示?

(1) $F_1 = P_1 F P_2 = 2\sqrt{hk} P F Q \xrightarrow{P F Q \triangleq \tilde{F}_1} 2\sqrt{hk} \tilde{F}_1.$

(2) 得 U_1 .

(3) $U_1 = P_1^T U P_2 \Rightarrow U = P_1 U_1 P_2^T = P_1 U_1 P_2 = 2\sqrt{hk} P U_1 Q.$

$$(U_1)_{ij} = \frac{(F_1)_{ij}}{\lambda_i + \mu_j} = \frac{2\sqrt{hk}(\tilde{F}_1)_{ij}}{\lambda_i + \mu_j}.$$

$$(U)_{ij} = \left(2\sqrt{hk}PU_1Q\right)_{ij} = (P\bar{U}_1Q)_{ij}, \text{ 其中 } \bar{U}_1 = 2\sqrt{hk}U_1, (\bar{U}_i)_{ij} = \frac{4jk}{\lambda_i + \mu_j}(\tilde{F}_1)_{ij}.$$

1.6.2 DST 算法

算法 1 求解 Poisson 方程五点差分格式的快速 DST 方法

步 1. 给出划分数 $I+1, J+1$, 得步长 $h = \frac{1}{I+1}, k = \frac{1}{J+1}$.

形成向量 λ , 其第 i 位置的元素 λ_i 为 $\lambda_i = \frac{4}{h^2} \sin^2 \frac{i\pi}{2(I+1)}, 1 \leq i \leq I$;

形成向量 μ , 其第 j 位置的元素 μ_j 为 $\mu_j = \frac{4}{k^2} \sin^2 \frac{j\pi}{2(J+1)}, 1 \leq j \leq J$;

形成矩阵 P , 其第 (i, j) 位置的元素为 $\sin \frac{ij\pi}{I+1}, 1 \leq i, j \leq I$;

形成矩阵 Q , 其第 (i, j) 位置的元素为 $\sin \frac{ij\pi}{J+1}, 1 \leq i, j \leq J$;

计算矩阵 F , 其第 (i, j) 位置的元素为 $f(ih, jk), 1 \leq i \leq I, 1 \leq j \leq J$.

步 2. 使用快速 DST 计算矩阵 $V = PFQ$; 在 MATLAB 中可写成:

`V = dst(dst(F)')'`;

步 3. 计算矩阵 $W = [w_{ij}]$,

$$w_{ij} = \frac{4v_{ij}}{(\lambda_i + \mu_j)(I+1)(J+1)}.$$

步 4. 使用快速 DST 计算矩阵 $U = PWQ$; 在 MATLAB 中可写成:

`U = dst(dst(W)')'`;

运算 PFQ 和 PWQ 可由离散正弦变换来实现.

1.6.3 各类算法计算时间的比较

表 1 中列出了各算法的计算时间, 其中迭代法终止条件是前后两步矩阵的 Frobenius 范数小于 10^{-6} . 容易看出快速 DST 方法优势明显.

表 1.1: 各类算法计算时间的比较 (单位: 秒)

划分数 N	DST	分块 LU 分解	Jacobi 迭代	G-S 迭代
10	0.001	0.002	0.006	0.002
20	0.002	0.008	0.05	0.02
40	0.008	0.04	1.0	0.6
80	0.012	0.14	7.5	4.3
160	0.048	1.3	111.6	62.5

△ 问题

试给出带 Dirichlet 边界条件的三维 Poisson 方程中心差分格式的快速求解方法.

1.7 两点边值问题的紧致差分格式

基于三个网格点 x_{i-1}, x_i, x_{i+1} 的格点函数值建立的中心差分格式 $-\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2} = f(x_i)$ 具有二阶精度 $O(h^2)$. 现在来根据这三个网格点上的格点函数值构造出求解原问题最高精度为 $O(h^4)$ 的差分格式, 称之为**紧致差分格式**.

设 $u(x) \in C^6[0, 1], v(x) \in C^4[0, 1]$, 记

$$\delta_x^2 u_i = \frac{u_{i-1} - 2u_i + u_{i+1}}{h^2}, \quad u_i = u(x_i).$$

则由 Taylor 展开知存在常数 $\xi_i, \eta_i \in (x_{i-1}, x_{i+1})$, 使得

$$\delta_x^2 u_i = u''(x_i) + \frac{1}{12}h^2 u^{(4)}(x_i) + \frac{2}{6!}h^4 u^{(6)}(\xi_i), \quad (3.1)$$

以及

$$\delta_x^2 v_i = v''(x_i) + \frac{1}{12}h^2 v^{(4)}(\eta_i). \quad (3.2)$$

这表明, 上述差分方程是二阶的, 那么能否用三点值构造出精度更高的格式?

第一个思路是既然 $u''(x) \approx \alpha_{-1}u_{i-1} + \alpha_0 u_i + \alpha_1 u_{i+1}$, 那么能否通过调整 α 的值得到更好的结果. 但可以证明, 中心差分格式已经是最优的结果了.

第二个想法是既然左侧是三点的线性组合, 那么右端是否也可以使用三点的线性组合构造, 即 $\alpha_{-1}u_{i-1} + \alpha_0 u_i + \alpha_1 u_{i+1} = \beta_{-1}f_{i-1} + \beta_0 f_i + \beta_1 f_{i+1}$ 是否可能带来高阶的精度? 在这种思路下, 数学家发现可以最终得到四阶的截断误差.

在 (3.2) 中令 $v = u''$, 并代入 (3.1), 可得

$$\begin{aligned} \delta_x^2 u_i &= u''(x_i) + \frac{1}{12}h^2 \left[\delta_x^2 u''(x_i) - \frac{1}{12}h^2 u^{(6)}(\eta_i) \right] + \frac{2}{6!}h^4 u^{(6)}(\xi_i) \\ &= \left(I + \frac{1}{12}h^2 \delta_x^2 \right) u''(x_i) - \frac{1}{144}h^4 u^{(6)}(\eta_i) + \frac{1}{360}h^4 u^{(6)}(\xi_i). \end{aligned}$$

定义算子

$$\mathcal{W}_x = I + \frac{1}{12}h^2 \delta_x^2, \quad (1.26)$$

即

$$\mathcal{W}_x v_i = \frac{1}{12}(v_{i-1} + 10v_i + v_{i+1}), \quad (3.3)$$

则

$$\mathcal{W}_x u''(x_i) = \delta_x^2 u_i + \rho_i(h), \quad (3.4)$$

式中 $\rho_i(h) = h^4 \left(\frac{1}{144}u^{(6)}(\eta_i) - \frac{1}{360}u^{(6)}(\xi_i) \right) = O(h^4)$.

现在考虑问题

$$-u''(x) = f(x), \quad 0 < x < 1; u(0) = \beta, \quad u(1) = \gamma$$

的求解. 先将区域等分为 $N+1$ 份. 对 $1 \leq i \leq N$, 在方程两边用算子 $\mathcal{W}_x$ 作用得

$$-\mathcal{W}_x u''(x_i) = \mathcal{W}_x f(x_i).$$

将 (3.4) 代入上式, 有

$$-(\delta_x^2 u_i + \rho_i(h)) = \mathcal{W}_x f(x_i).$$

忽略高次项, 得如下差分方法

$$\begin{cases} -\frac{u_{i-1} - 2u_i + u_{i+1}}{h^2} = \frac{1}{12}(f_{i-1} + 10f_i + f_{i+1}), & 1 \leq i \leq N, \\ u_0 = \beta, & u_{N+1} = \gamma. \end{cases} \quad (1.27)$$

以上方法写成矩阵形式为

$$AU = BF + G, \quad (3.5)$$

式中 A, B 为 $N \times N$ 的矩阵, 具体形式为

$$A = -\frac{1}{h^2} \begin{bmatrix} -2 & 1 & & \\ 1 & -2 & \ddots & \\ & \ddots & \ddots & 1 \\ & & 1 & -2 \end{bmatrix}, \quad B = \frac{1}{12} \begin{bmatrix} 10 & 1 & & \\ 1 & 10 & \ddots & \\ & \ddots & \ddots & 1 \\ & & 1 & 10 \end{bmatrix},$$

$$U = [u_1, u_2, \dots, u_N]^T, \quad F = [f_1, f_2, \dots, f_N]^T,$$

$$G = \left[\frac{1}{12}f_0 + \frac{1}{h^2}u_0, 0, \dots, 0, \frac{1}{12}f_{N+1} + \frac{1}{h^2}u_{N+1} \right]^T.$$

由

$$A = -\frac{1}{h^2}(-2I + H_N), \quad B = \frac{1}{12}(10I + H_N)$$

知, A 和 B 的特征值分别为

$$\lambda_i = \frac{4}{h^2} \sin^2 \frac{\theta_i}{2}, \quad \mu_i = \frac{1}{6}(5 + \cos \theta_i),$$

式中 $\theta_i = i\pi/(N+1)$, 相应的特征向量均为

$$\mathbf{p}_i = [\sin(\theta_i), \sin(2\theta_i), \dots, \sin(N\theta_i)]^T, \quad 1 \leq i \leq N.$$

设 U, F 在基 $\{\mathbf{p}_i: 1 \leq i \leq N\}$ 下表示为

$$U = \sum_{i=1}^N w_i \mathbf{p}_i, \quad F = \sum_{i=1}^N v_i \mathbf{p}_i.$$

在 MATLAB 中当知道 $\mathbf{w} = [w_1, \dots, w_N]^T$ 时, 可用离散正弦变换 (dst) 获得 U , 而 $\mathbf{v} = [v_1, \dots, v_N]^T$ 可用离散正弦变换的逆变换 (idst) 获得. 把以上表示代入方程 (3.5) 中可知

$$\sum_{i=1}^N w_i \lambda_i \mathbf{p}_i = \sum_{i=1}^N v_i \mu_i \mathbf{p}_i + \mathbf{G},$$

两边用 $\mathbf{p}_j$ 做内积, 并注意到 $\langle \mathbf{p}_i, \mathbf{p}_j \rangle = (N+1)/2$, 可知

$$w_j = \frac{1}{\lambda_j} (v_j \mu_j + 2/(N+1) \langle \mathbf{G}, \mathbf{p}_j \rangle).$$

注意到 $\mathbf{G}$ 的表达式, 可推得

$$\langle \mathbf{G}, \mathbf{p}_j \rangle = G_1 \sin(\theta_j) + G_N \sin(N\theta_j), \quad (3.6)$$

式中 G_1 和 G_N 分别为向量 $\mathbf{G}$ 的第 1 和 N 个分量, 进而获得解 U .

综上所述, 我们获得求解问题 (3.5) 的如下快速算法:

算法 2 求解两点边值问题的快速算法

步 1. 给定划分数 $L+1$, 得步长 $h = 1/(N+1)$.

- 形成向量 θ ，其第 i 位置的元素 θ_i 为 $i\pi/(N+1)$, $1 \leq i \leq N$ ，进而形成 λ 和 μ ；
- 形成向量 G_p ，它的分量如 (3.6) 所示；
- 形成向量 F ；

步 2. 用离散正弦变换的逆变换计算向量 v ，在 MATLAB 中如下执行： $v = \text{idst}(F)$ 。

步 3. 计算系数向量 w ，在 MATLAB 中如下执行：

$$w = 1./\text{lambda}.*(v.*\mu+2/(L+1)*Gp);$$

步 4. 对 w 求离散正弦变换，获得解 U ： $U = \text{dst}(w)$ 。

例 3.1 考虑问题

$$\begin{cases} -u''(x) = 6e^{-x^2}(1-2x^2), & -1 < x < 1, \\ u(-1) = 3e^{-1}, \quad u(1) = 3e^{-1}, \end{cases} \quad (\text{例 3.1})$$

精确解为 $u(x) = 3e^{-x^2}$ 。

定义离散 L^2 误差为

$$\text{error} = \sqrt{h \sum_{i=1}^N |u_i - u(x_i)|^2}.$$

计算结果如下：

Table: 一维问题紧致差分格式的误差分析

N	8	16	32	64	128
Error	4.9431e-04	3.8358e-05	2.6921e-06	1.7868e-07	1.1515e-08
Rate	-	3.6878	3.8327	3.9132	3.9558